

📈 Forecast de Vendas Semanais — Dashboard Executivo

Previsões semanais com aprendizado de máquina (RandomForest e XGBoost), sem vazamento de dados, com foco em clareza para decisão.

💡 O que você está vendo

- **O que é:** previsões semanais de vendas, usando um modelo que aprende com o comportamento passado e fatores de calendário/economia.
- **Como funciona:** o modelo “olha” as semanas anteriores (memória), entende sazonalidade (meses do ano) e ajusta previsões semana a semana.
- **Por que confiar:** as previsões são feitas **sem olhar o futuro** — cada previsão alimenta a próxima, como aconteceria na operação real.
- **Como ler os KPIs:**
 - **RMSE:** quanto erramos, em média, nas unidades de venda. Menor é melhor.
 - **R²:** quanto da variação das vendas o modelo explica (de 0 a 1). Maior é melhor.
 - **MAPE:** erro percentual médio. Menor é melhor.

12 34 KPIs de Precisão (período de teste)

Melhor RMSE

75,077

Melhor R²

0.56

Melhor MAPE (%)

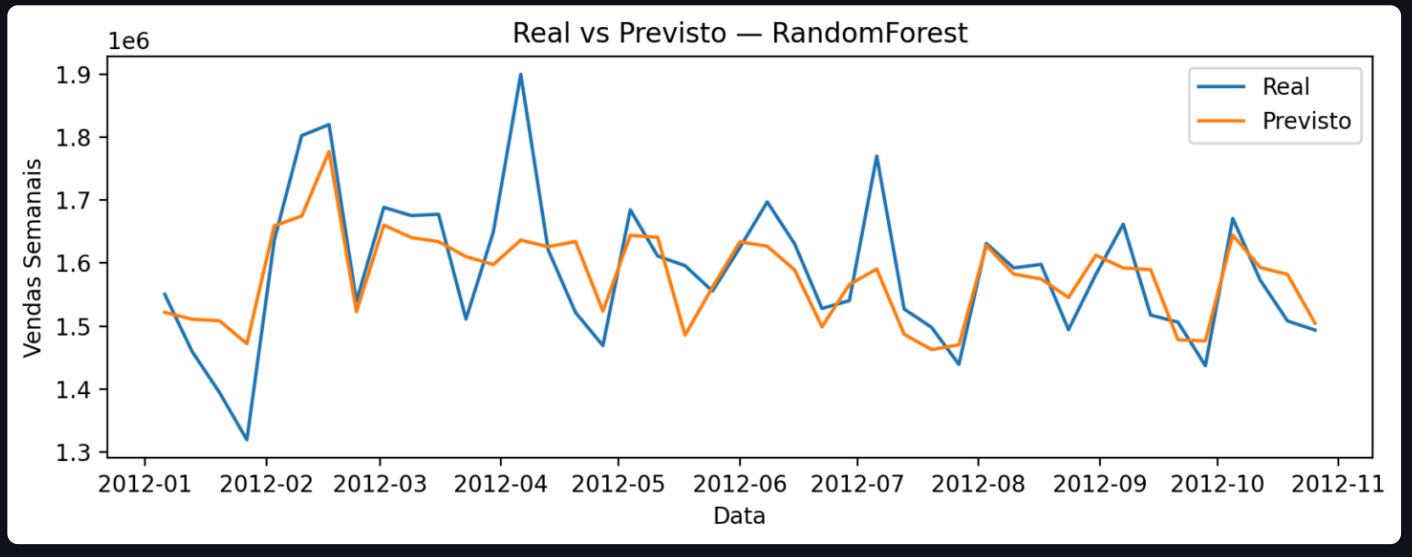
3.43

	Modelo	RMSE	R ²
0	RandomForest	75076.5448	
1	XGBoost	92337.4653	

📈 Real vs Previsto

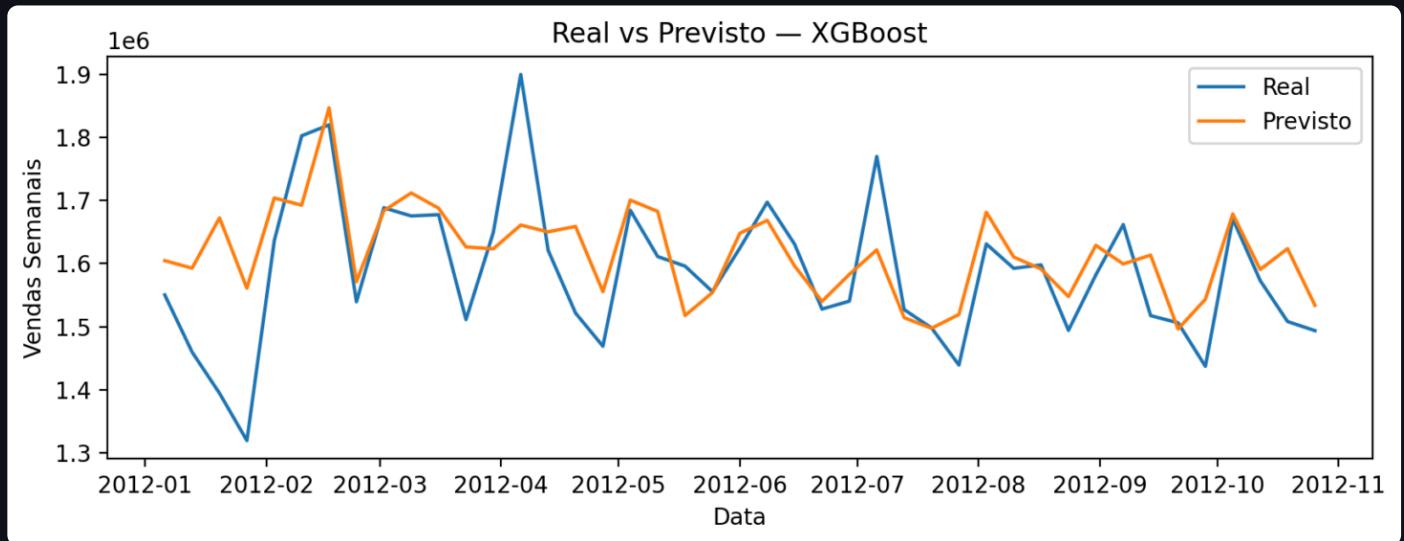
RandomForest

Este gráfico compara o valor real de vendas (linha azul) com o valor previsto pelo modelo (linha laranja) ao longo das semanas. Podemos observar que as duas linhas seguem um formato parecido, indicando que o modelo consegue capturar a tendência geral das vendas. Em algumas semanas existe uma diferença maior entre as linhas, o que normalmente acontece em períodos com eventos fora do padrão, como promoções, sazonalidade ou mudanças de mercado.



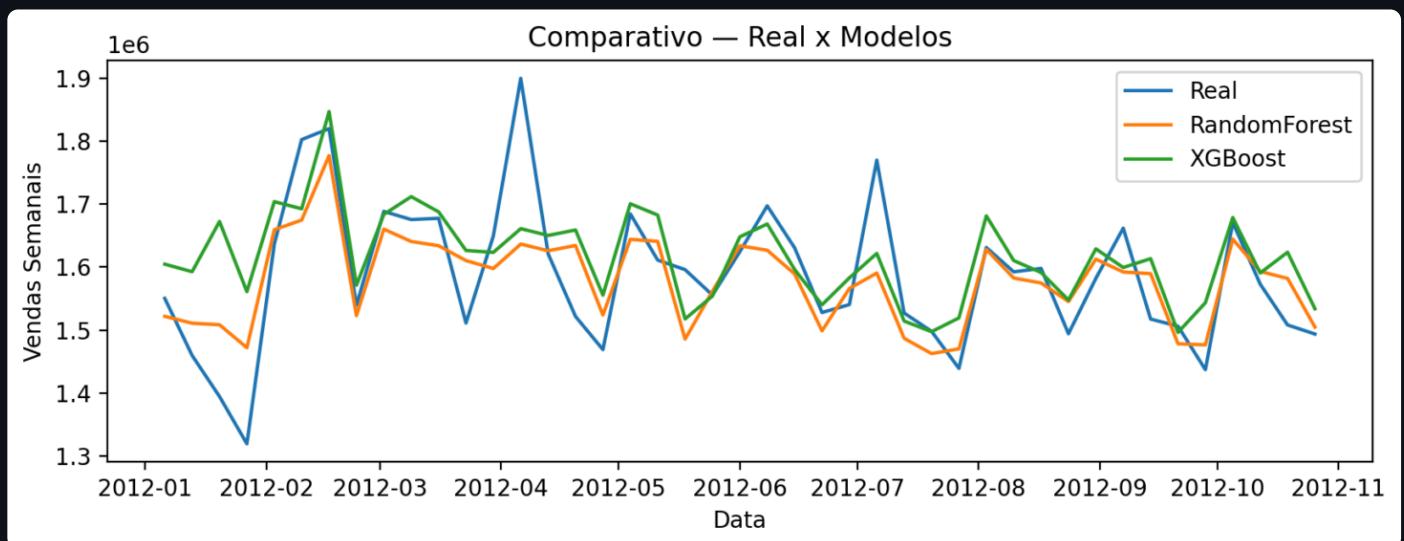
XGBoost

Neste gráfico vemos a comparação entre as vendas reais (linha azul) e as vendas previstas pelo modelo XGBoost (linha laranja). As duas linhas acompanham bem o movimento geral das vendas ao longo dos meses, mostrando que o modelo consegue entender a tendência e o comportamento do negócio. Em alguns pontos o modelo suaviza variações mais bruscas, o que é comum em modelos que buscam estabilidade. No geral, o XGBoost apresenta boa aderência, especialmente em períodos mais estáveis, sendo útil para previsões de planejamento.



Comparativo entre os modelos

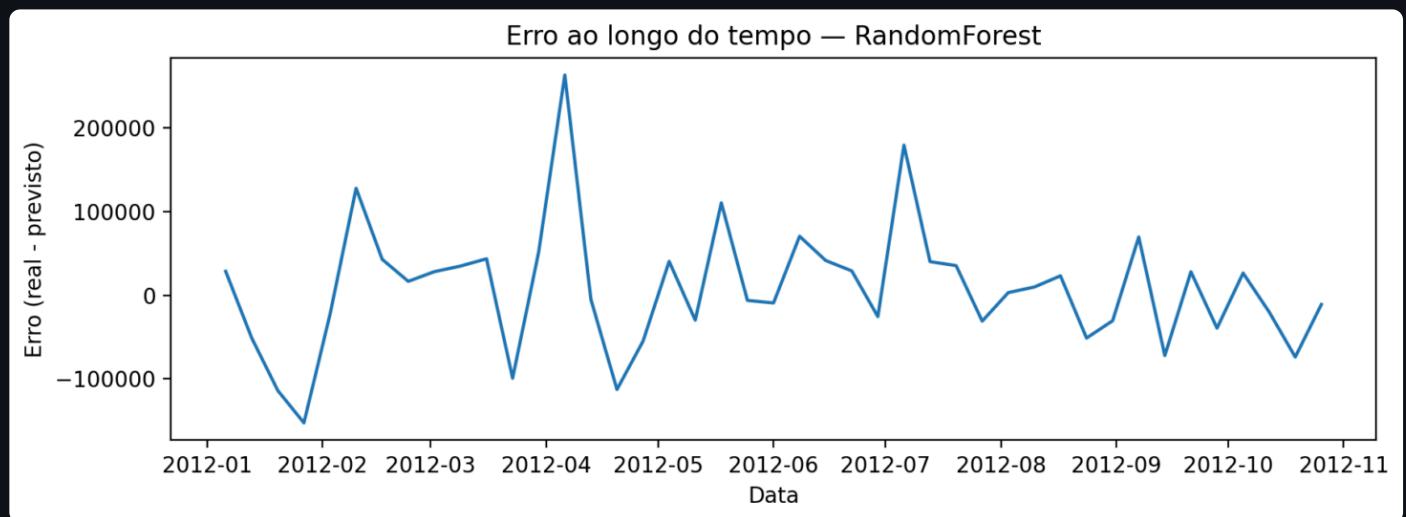
Este gráfico coloca lado a lado as vendas reais e as previsões dos dois modelos. A linha azul representa o que realmente aconteceu, enquanto as linhas laranja (RandomForest) e verde (XGBoost) mostram as previsões. Observamos que ambos os modelos conseguem seguir a tendência geral das vendas ao longo do tempo. O XGBoost acompanha melhor oscilações mais rápidas, ficando mais próximo de picos e vales. Já o RandomForest tende a ser mais conservador, suavizando variações e mantendo previsões mais estáveis, o que é importante para planejamento e tomada de decisão, evitando reações exageradas a semanas atípicas. Por isso, apesar de pequenas diferenças, o RandomForest foi escolhido como modelo principal, por oferecer maior consistência e menor risco operacional no uso das previsões.



Diagnóstico de Erros

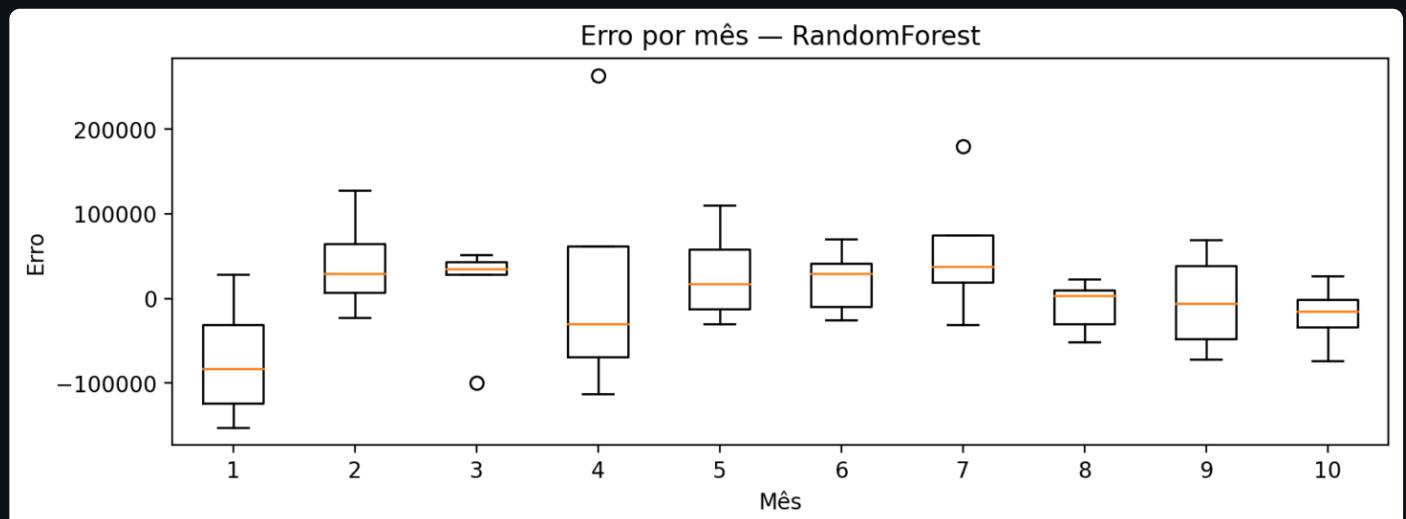
Erro ao longo do tempo — RandomForest

Este gráfico mostra a diferença entre o valor real e o valor previsto pelo modelo em cada semana. Quando a linha está próxima de zero, significa que o modelo acertou bem. Os picos positivos e negativos representam semanas em que houve mudanças fora do padrão, como promoções, sazonalidade ou fatores externos. No geral, o modelo mantém o erro controlado e sem desvios prolongados, o que indica que ele é estável e adequado para uso no planejamento.



Erro ao longo do tempo — RandomForest

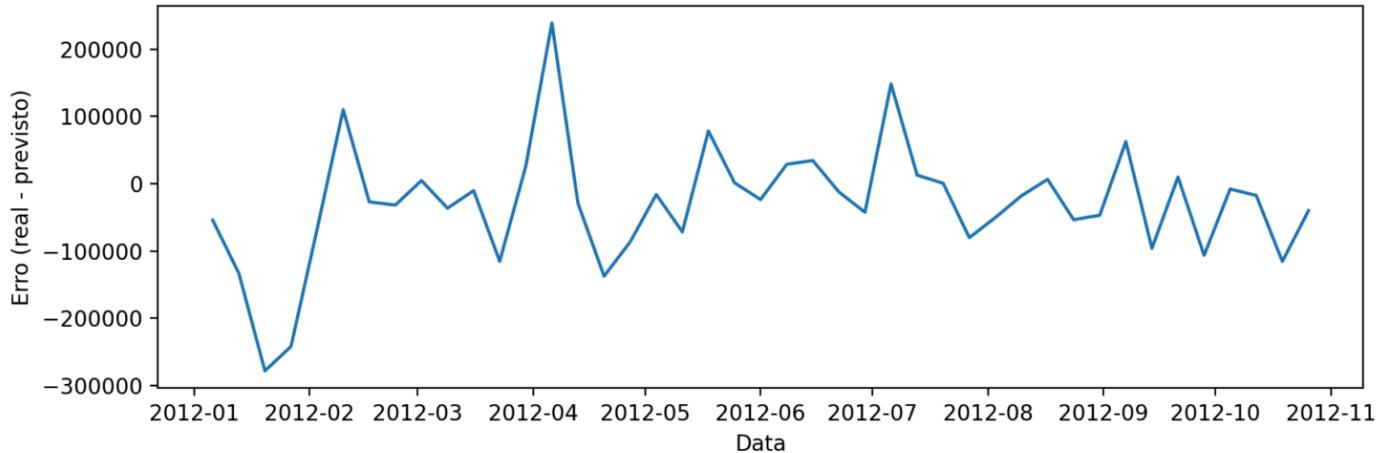
Este gráfico mostra como o erro do modelo se comporta em cada mês. Meses onde a caixa é mais alta ou espalhada indicam maior variação nas vendas, ou seja, semanas mais diferentes do padrão esperado. Já meses com caixas mais compactas indicam que o modelo conseguiu prever com maior estabilidade. De forma geral, o modelo mantém um desempenho consistente ao longo do ano, com variações naturais em períodos de maior movimentação ou sazonalidade.



Erro ao longo do tempo — XGBoost

Este gráfico mostra como o erro do XGBoost varia ao longo das semanas. Assim como no RandomForest, quando a linha está próxima de zero, o modelo acertou bem. Porém, percebemos picos mais intensos, tanto para cima quanto para baixo, indicando que o XGBoost é mais sensível a mudanças bruscas no comportamento das vendas. Essa maior oscilação pode levar a previsões menos estáveis em semanas atípicas. Por isso, mesmo apresentando bom desempenho, optamos pelo RandomForest como modelo principal, pois ele oferece maior equilíbrio e consistência, o que é mais seguro para o planejamento.

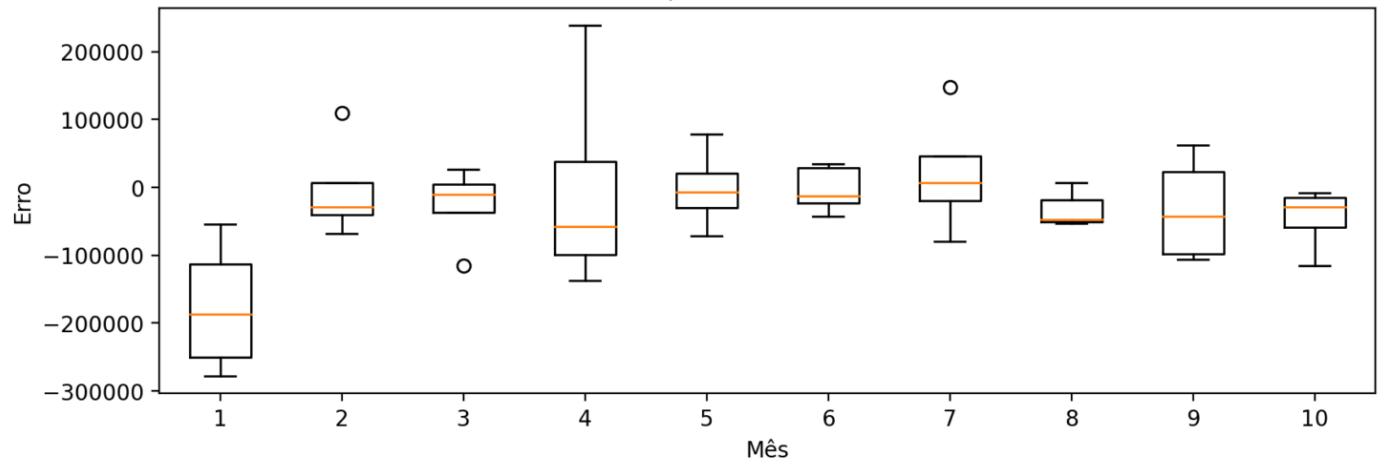
Erro ao longo do tempo — XGBoost



Erro ao longo do tempo — XGBoost

Este gráfico mostra como o erro do XGBoost varia mês a mês. Percebemos que, em alguns meses, a distribuição do erro é mais espalhada, indicando que o modelo é mais sensível a mudanças bruscas no comportamento das vendas. Essa sensibilidade pode fazer com que o modelo reaja demais a semanas atípicas, ampliando o erro em períodos de maior variação ou sazonalidade. Embora o XGBoost acompanhe bem oscilações, essa maior instabilidade mensal reforça a escolha do RandomForest como modelo principal, pois ele mantém previsões mais estáveis e consistentes, o que é ideal para o planejamento do negócio.

Erro por mês — XGBoost

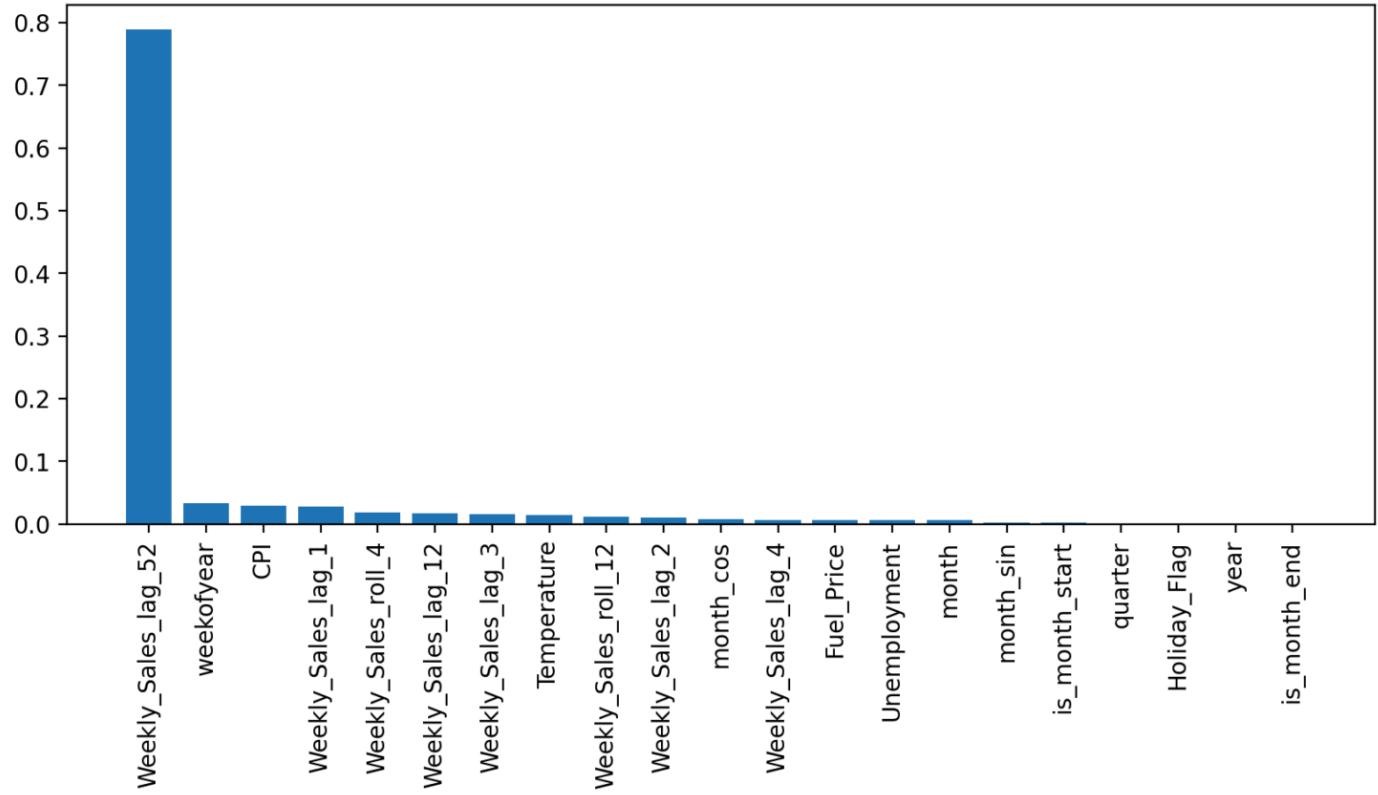


💡 Importância de Features (o que mais pesa nas previsões)

RandomForest

Este gráfico mostra quais informações o modelo mais utiliza na hora de prever as vendas. A variável com maior peso é Weekly_Sales_lag_52, que representa as vendas da mesma semana do ano anterior. Isso indica que o negócio possui um forte padrão sazonal, ou seja, períodos do ano tendem a repetir comportamentos de vendas. Outros fatores que também influenciam as previsões são a semana do ano, inflação (CPI) e as vendas das semanas mais recentes, mostrando que o modelo aprendeu tanto o ciclo anual quanto o ritmo das últimas semanas. Em resumo: o modelo consegue capturar tendência + sazonalidade, o que reforça sua capacidade de prever com consistência.

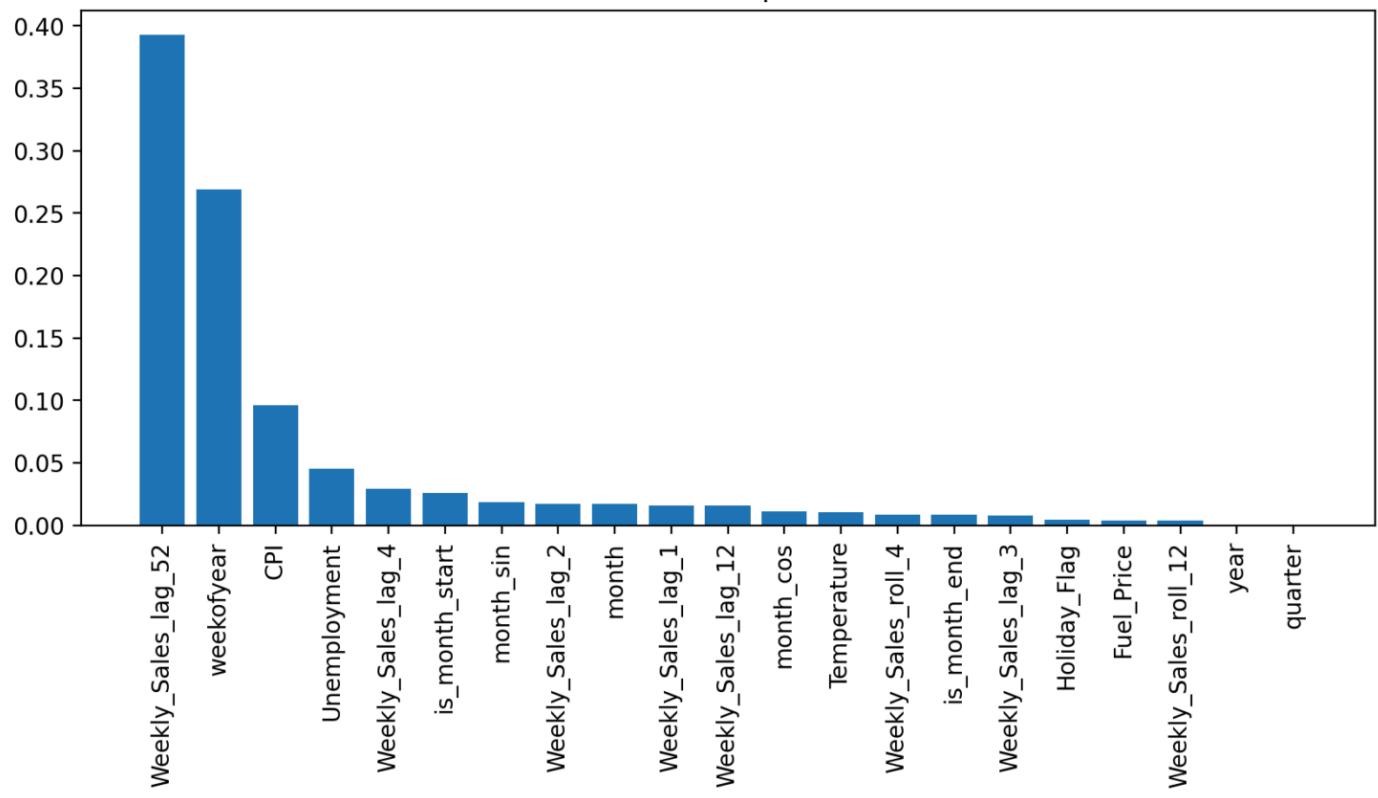
RandomForest — importância



XGBoost

Assim como no RandomForest, o XGBoost também identifica a sazonalidade anual como o principal fator, com a variável "Weekly_Sales_lag_52" sendo a mais relevante. Além disso, o modelo dá destaque à semana do ano ("weekofyear") e a indicadores econômicos como CPI e Unemployment, mostrando que ele é mais sensível a variações externas. Esse comportamento reforça que o XGBoost reage mais rapidamente a mudanças no ambiente, o que pode ser positivo, mas também pode aumentar a instabilidade das previsões. Por isso, mesmo com boa capacidade de identificar padrões, optamos pelo RandomForest como modelo principal, pois ele mantém previsões mais estáveis e adequadas para planejamento.

XGBoost — importância



▼ Como ler este dashboard

KPIs (no topo)

- RMSE: quanto erramos em valor absoluto.
- R²: o quanto explicamos da variação das vendas.
- MAPE: erro percentual médio.

Gráficos de linha

- Comparam vendas reais com as previsões. Linhas próximas indicam boa aderência.

Erro ao longo do tempo

- Se oscila ao redor de zero, o modelo está equilibrado.
- Picos revelam semanas “especiais” (ex.: feriados, promoções).

Erro por mês (boxplot)

- Mostra meses onde o modelo é mais instável.
- Útil para planejar ações (ex.: reforço de dados/variáveis em meses problemáticos).

Importância de Features

- Indica quais informações o modelo realmente usa para prever.
- Se “lags” aparecem no topo, o histórico recente é muito relevante.

Analítico Anônimos

Nome	RM
Cesar Miyashiro	RM556286
Helder Gualdi de Godoy	RM556571
Liora Vanessa Dopacio	RM554355
Marcelo Moure	RM555751
Sandro Façanha	RM557585